

Assistente

Médico

LLM local + RAG + segurança

Tech Challenge – Fase 3

Jefferson Antônio Pantoja Silva | 12 de setembro de 2026

O desafio

Como responder dúvidas médicas com contexto, rastreabilidade e segurança? O

sistema deve combinar conhecimento biomédico, informações do paciente e mecanismos explícitos de proteção.


Objetivo

Construir um pipeline modular que prepare dados, ajuste uma LLM, consulte prontuários sintéticos e gere respostas contextualizadas.

Limite de uso

Apoio informacional. Não substitui avaliação ou decisão de um profissional de saúde.

Visão geral da solução



Ideia central

O modelo gera a resposta, mas o contexto recuperado, as fontes e a revisão automática tornam o fluxo mais controlável e auditável.

Dados: curadoria antes do modelo

Fontes públicas

- ▶ MedQuAD: XML com perguntas e respostas do NIH.
- ▶ PubMedQA: JSON com pergunta, contexto e resposta biomédica.
- ▶ Nenhum dado real de paciente é usado na demonstração.

Tratamento aplicado

- ▶ Normalização de texto e validação de campos.
- ▶ Remoção de vazios, registros curtos e duplicidades.
- ▶ Preservação de source para rastreabilidade.
- ▶ Leitura e escrita incrementais em JSONL.

Saída

Cada linha contém source e text, usando o mesmo template na preparação e na inferência.

Fine-tuning eficiente no Colab

1. Dataset separado em treino e teste.
2. Modelo base Llama-3.2-1B-Instruct em 4-bit.
3. Adaptação com QLoRA e Unsloth.
4. Treino supervisionado com `trl.SFTTrainer`.
5. Merge do adapter e salvamento do modelo final.

O treinamento é executado no Google Colab; a inferência usa o modelo local mesclado.

Parâmetros principais

LoRA $r = 16$ | $\alpha = 32$
dropout = 0,05
batch = 2 | acumulação = 8
learning rate = 2×10^{-4}
1 época | BF16/FP16

Avaliação do modelo fine-tuned | 1,5 minutos

Protocolo

- ▶ Amostra aleatória de 500 itens do teste.
- ▶ Teste separado via `train_test_split`.
- ▶ Apenas o fine-tuned; sem comparação com o modelo base.

Interpretação

Métricas textuais não comprovam factualidade ou validade clínica.

Resultados registrados

Métrica	Resultado
Exact Match	0,0000
Token F1	0,3280
ROUGE-L	0,2717
BERTScore F1	0,8354

Exact Match nulo e Token F1/ROUGE-L moderados indicam baixa correspondência literal. O BERTScore sugere similaridade semântica, mas não garante correção factual.

Prontuários sintéticos e rastreabilidade

Um caso curado é convertido em um prontuário fictício com estrutura consistente:

- ▶ queixa principal e histórico;
- ▶ medicamentos e sinais vitais;
- ▶ avaliação e plano;
- ▶ origem e identificador do paciente.

Confiabilidade do pipeline

Os lotes são validados pela presença de exatamente uma ocorrência de cada source. Respostas inválidas podem ser reprocessadas até três vezes.


Retomada

O JSONL é gravado progressivamente e checkpoints evitam repetir registros já concluídos.

Arquitetura e fluxo RAG

Clean Architecture

- ▶ domain: modelos imutáveis.
- ▶ application: casos de uso e portas.
- ▶ infrastructure: LLM, FAISS, OpenAI e Langfuse.
- ▶ presentation: controladores CLI.



Contexto clínico com controle de risco

Recuperação

- ▶ Busca semântica com all-MiniLM-L6-v2.
- ▶ Até quatro documentos relevantes.
- ▶ Filtro opcional pelo `patient_id`.
- ▶ Fontes retornam junto da resposta.

Salvaguardas

- ▶ O campo `plan` fica fora do contexto RAG.
- ▶ Pedidos de medicamento ou tratamento são revisados.
- ▶ A resposta inclui aviso de avaliação profissional.
- ▶ Há fallback se a revisão externa falhar.

Demonstração ao vivo | 3 minutos

Sequência da execução

1. Iniciar o assistente e selecionar um paciente.
2. Perguntar sobre um dado do prontuário.
3. Repetir a pergunta em português.
4. Solicitar medicamento ou tratamento.
5. Conferir resposta, aviso e fontes.

O que comprovar

A resposta muda conforme o paciente, retorna as fontes recuperadas e não apresenta uma prescrição direta.

```
python3 -m src.main_rag \  
  --model-dir resources/medqa-finetuned-  
    model \  
  --patient-records resources/  
    patient_records.jsonl \  
  --top-k 4
```


O idioma original é preservado: a pergunta pode ser traduzida para o inglês e a resposta volta ao idioma do usuário.

Antes de começar: modelo local, prontuários e API configurados.

Leitura do trace no Langfuse | 2 minutos

No dashboard, mostrar:

1. Trace da requisição recém-executada.
2. Nós de tradução, recuperação e contexto.
3. `local_model_generation` e traduções.
4. `review_medical_response` no final.
5. Tokens, latência e metadados da requisição.



Privacidade por padrão

`LANGFUSE_CAPTURE_CONTENT=false`: registrar metadados sem capturar o conteúdo clínico integral.

Contingência: usar a captura de tela; o assistente continua sem tracing.

Resultado, limites e próximos passos | 1 minuto

O que foi implementado

- ▶ Pipeline de dados e curadoria.
- ▶ Geração de prontuários sintéticos.
- ▶ Fine-tuning documentado com QLoRA.
- ▶ RAG com FAISS e filtro por paciente.
- ▶ Segurança, fontes e tracing.

Próximas medições

- ▶ Perda final do treinamento.
- ▶ Qualidade da recuperação.
- ▶ Avaliação clínica por especialistas.
- ▶ Robustez multilíngue e fora do domínio.

Base técnica executável e auditável, não um sistema de decisão clínica.

Obrigado

Perguntas?

Projeto: Assistente Médico com LLM, RAG e LangChain